

Informe de Calidad de Datos

Dataset de ventas NovaMarket

Cierre de la Misión 1

Autores: Daniel Pallarés, Sofía Arbeláez y Juan Sánchez (Unidad de Datos).
Dataset auditado: NovaMarket datos crudos (640.000 registros y 20 columnas).
Fecha de referencia: 4 de agosto de 2026.

1. Resumen ejecutivo

El dataset de ventas de NovaMarket tiene una confiabilidad media. Hoy sirve para explorar los datos de forma interna, pero todavía no está listo para reportar resultados al comité ni para alimentar modelos de decisión, porque arrastra varios errores importantes a gran escala.

Los tres focos más graves son la falta de consistencia en el texto (categoría de producto, ciudad, canal y método de pago, que afectan entre el 20 % y el 65 % de los registros), el inventario desactualizado (más de la mitad de los registros con stock de más de 90 días) y los pedidos duplicados. A esto se suman valores imposibles en precio, unidades, edad y peso, y un 16 % de correos faltantes.

En conclusión, el dataset es confiable para diagnóstico, pero aún no para tomar decisiones. Un dato tranquilizador: la regla de negocio monto = precio por unidades se cumple en el 100 % de los registros, así que el monto sí es un campo derivado confiable. El Plan de Saneamiento explica cómo se va a corregir cada problema.

2. Alcance y metodología

Se auditó el archivo de ventas de NovaMarket, con 640.000 filas y 20 columnas, que registra pedidos con fecha de compra en 2025 y 2026, tomando como fecha de referencia el 4 de agosto de 2026. Todo el análisis se hizo de forma vectorizada por la escala del dataset. La revisión se hizo sobre las seis dimensiones de calidad de datos:

- Completitud: cuántos valores están presentes y cuántos faltan.
- Exactitud: si los valores son posibles (sin negativos, dentro de rango, sin fechas futuras).
- Consistencia: si un mismo dato se escribe siempre de la misma forma.
- Validez: si los valores cumplen el formato esperado (correo, fecha, código postal).
- Unicidad: si cada pedido aparece una sola vez.
- Oportunidad: si los datos siguen estando actualizados.

3. Hallazgos por dimensión

Todos los porcentajes se calculan sobre los 640.000 registros.

Compleitud

Cinco columnas tienen datos faltantes. El correo es la más crítica, con 105.312 vacíos (16,46 %), lo que deja a esos clientes fuera de las campañas por correo. Le siguen el comentario del cliente con 90.806 (14,19 %), que es un campo opcional de texto libre; la satisfacción con 46.469 (7,26 %); la ciudad de la tienda con 29.928 (4,68 %); y el precio junto con el monto, que faltan en las mismas 21.640 filas (3,38 %). Al diagnosticar por qué faltan, la mayoría resultó completamente al azar (MCAR); solo la satisfacción depende del canal (falta sobre todo en compras por App). Las otras columnas están completas.

Exactitud

Hay valores imposibles en varias columnas numéricas. Las unidades vendidas inválidas (negativas, en cero o con valores centinela como 5000 y 9999) son 46.403 (7,25 %); el peso del pedido supera los 100 kg en 32.045 registros (5,01 %), incluso en productos livianos, lo que apunta a un error de captura; la edad está fuera de rango físico en 27.829 (4,35 %); y el precio es negativo en 19.629 (3,07 %). Además, 16.485 pedidos (2,58 %) tienen fecha futura. Estos valores falsean directamente el cálculo de ingresos y de unidades vendidas.

Consistencia

Es el problema más extendido. La categoría de producto tiene 32 formas de escribir 6 categorías reales: 416.457 registros (65,07 %). La ciudad de la tienda tiene 88 variantes para 12 ciudades (mayúsculas, tildes rotas, abreviaturas como BOG o MDE y sufijos): 391.920 (61,24 %). El canal de compra pasa de 20 valores a 4 reales por mayúsculas y espacios sobrantes: 154.781 (24,18 %); el método de pago, lo mismo: 129.372 (20,21 %); y la satisfacción, de 15 valores a 3 niveles: 95.706 (14,95 %). Además, 42.405 registros (6,63 %) tienen un código postal cuyo departamento no coincide con la ciudad declarada. Mientras el texto no se unifique, no se pueden agrupar bien las ventas y cualquier informe sale distorsionado.

Validez

El código postal es el caso más llamativo: 106.725 registros (16,68 %) no tienen los 7 dígitos del formato DIVIPOLA, porque perdieron el cero inicial del departamento al guardarse como número; se concentra casi todo en Medellín y Barranquilla (departamentos 05 y 08). También hay 51.532 correos con formato inválido (8,05 %) y 22.687 fechas de pedido con formato incorrecto o inexistente (3,54 %), como un 30 de febrero o un mes 13. Con estos errores no se puede geolocalizar clientes, los correos rebotan y esas ventas no se pueden ordenar por tiempo.

Unicidad

Hay 20.000 filas totalmente repetidas (3,12 %) y, en total, 40.000 registros (6,25 %) comparten un id de pedido que debería ser único, es decir 20.000 pedidos duplicados. Por eso ese identificador todavía no sirve como llave para contar pedidos, y los duplicados inflan los totales de ventas, unidades e ingresos.

Oportunidad


Es el hallazgo individual más grande: 327.601 registros (51,19 %) tienen el inventario desactualizado por más de 90 días respecto a la fecha de referencia. Más de la mitad del stock reportado no refleja la realidad, lo que en categorías de alta rotación lleva a decisiones equivocadas de reposición y a quiebres. Otros 21.722 registros (3,39 %) tienen fecha de stock en el futuro, lo que evidencia un error de captura.

4. Catálogo de problemas priorizado

La tabla reúne los 23 problemas encontrados, de mayor a menor severidad. La severidad combina el porcentaje de registros afectados con la importancia de la columna para el negocio; los duplicados se marcan siempre como altos porque distorsionan cualquier métrica agregada. La gráfica siguiente resume los de mayor alcance.

Dimensión	Problema	Cant.	%	Sev.	Impacto en el negocio
Consistencia	Categoría de producto: 32 variantes para 6 categorías	416.457	65,07	Alta	No se puede agrupar ni analizar ventas por categoría.
Consistencia	Ciudad de tienda: 88 variantes para 12 ciudades	391.920	61,24	Alta	Impide segmentar y planear logística por ciudad.
Oportunidad	Stock desactualizado (más de 90 días)	327.601	51,19	Alta	El inventario mostrado no es el real: riesgo de quiebres.
Consistencia	Canal de compra: variantes y espacios sobrantes	154.781	24,18	Alta	Distorsiona el análisis de ventas por canal.
Consistencia	Método de pago: variantes y espacios sobrantes	129.372	20,21	Alta	Distorsiona el análisis de pagos.
Compleitud	Correo faltante	105.312	16,46	Alta	Esos clientes no reciben campañas por correo.
Exactitud	Unidades negativas, en cero o centinela (5000/9999)	46.403	7,25	Alta	Corrompe el total de unidades vendidas e ingresos.
Unicidad	Id de pedido repetido (20.000 pedidos)	40.000	6,25	Alta	No sirve como llave para contar pedidos.
Validez	Fecha de pedido con formato inválido o inexistente	22.687	3,54	Alta	No se pueden ordenar esas ventas por tiempo.
Compleitud	Precio y monto faltantes (mismas filas)	21.640	3,38	Alta	Bloquea el cálculo de ingresos de esos pedidos.
Unicidad	Filas completamente duplicadas	20.000	3,12	Alta	Infla pedidos, unidades e ingresos.
Exactitud	Precio unitario negativo	19.629	3,07	Alta	Falsea la facturación real.
Consistencia	Satisfacción: 15 variantes para 3 niveles	95.706	14,95	Media	Impide medir bien la satisfacción del cliente.
Validez	Correo con formato inválido	51.532	8,05	Media	Esos correos rebotan al enviar campañas.
Compleitud	Satisfacción faltante	46.469	7,26	Media	Reduce la muestra de satisfacción.
Consistencia	Código postal no coincide con la ciudad (DIVIPOLA)	42.405	6,63	Media	Genera errores de ruteo y geografía.
Exactitud	Peso imposible (más de 100 kg por producto)	32.045	5,01	Media	Falsea costos de envío y planeación logística.
Exactitud	Fecha de pedido futura (imposible)	16.485	2,58	Media	Contamina los reportes de ventas por fecha.
Validez	Código postal sin los 7 dígitos DIVIPOLA	106.725	16,68	Baja	Pierde precisión geográfica (dato secundario).

Dimensión	Problema	Cant.	%	Sev.	Impacto en el negocio
Completitud	Comentario faltante (texto libre opcional)	90.806	14,19	Baja	Menos texto para análisis de opinión.
Completitud	Ciudad de tienda faltante	29.928	4,68	Baja	No ubica esos pedidos para logística.
Exactitud	Edad fuera de rango (negativa o mayor a 100)	27.829	4,35	Baja	Sesga la segmentación por edad.
Oportunidad	Fecha de stock futura (imposible)	21.722	3,39	Baja	Error de captura en la fecha de inventario.



Los problemas con mayor porcentaje de registros afectados, coloreados por severidad. El código postal y el comentario afectan a un porcentaje alto pero su severidad es baja, porque no comprometen la facturación ni la trazabilidad.

5. Conclusión de confiabilidad

El dataset de NovaMarket tiene una confiabilidad media. Hoy sirve para explorar los datos y priorizar la limpieza, pero no para reportar ventas, medir satisfacción ni segmentar clientes con seguridad. La mayor parte de los problemas son de consistencia de texto y de formato, que son corregibles, y el campo de facturación derivado (monto) es confiable; por eso el veredicto es medio y no bajo. Aplicando el Plan de Saneamiento durante la Misión 2, el dataset puede llegar a una confiabilidad alta y quedar listo para las decisiones del comité.

