

Plan de Saneamiento

Dataset de ventas NovaMarket

Hoja de ruta de limpieza para la Misión 2

Autores: Daniel Pallares, Sofía Arbeláez y Juan Sánchez (Unidad de Datos).

Documento asociado: Informe de Calidad de Datos de NovaMarket.

1. Propósito

El Informe de Calidad de Datos muestra qué tan mal están los datos. Este plan responde qué se va a hacer con cada problema y cuándo. La tabla ordena los 23 problemas del catálogo por prioridad, y a cada uno le asigna una estrategia y la semana de la Misión 2 en que se resuelve. La prioridad combina el porcentaje de registros afectados con el impacto en el negocio. Cada problema tiene su fila, así que ninguno queda sin plan.

Los cinco problemas de datos faltantes ya se trataron en la Misión 1 (Semana 4). Aparecen marcados como resueltos, para no perder el rastro de ninguno.

2. Tabla de saneamiento

Problema	Estrategia propuesta	Prioridad	Semana de la Misión 2
Categoría de producto: 32 variantes para 6 categorías	Normalizar el texto (minúsculas, tildes, espacios) y mapear a 6 categorías	Alta	Semana 6
Ciudad de tienda: 88 variantes para 12 ciudades	Estandarizar texto, resolver abreviaturas y sufijos, y mapear a 12 ciudades	Alta	Semana 6
Stock desactualizado (más de 90 días)	Crear una variable de antigüedad y un indicador; escalar a Operaciones para el refresco del inventario	Alta	Semana 10
Canal de compra: variantes y espacios sobrantes	Normalizar mayúsculas y espacios a los 4 canales reales	Alta	Semana 6
Método de pago: variantes y espacios sobrantes	Normalizar mayúsculas y espacios a los 4 métodos reales	Alta	Semana 6
Correo faltante (105.312)	Valor constante y columna indicadora; no se imputa por grupo (dato casi único por cliente)	Alta	Misión 1 (resuelto)
Unidades negativas, en cero o centinela (5000/9999)	Detectar por reglas de rango y tratar como atípicos: corregir o marcar	Alta	Semana 7
Id de pedido repetido (20.000 pedidos)	Deduplicar por id de pedido y restablecerlo como llave primaria	Alta	Semana 6
Fecha de pedido con formato inválido o inexistente	Pasar todo a un solo formato y marcar las fechas imposibles	Alta	Semana 6
Precio y monto faltantes (mismas filas)	Imputar precio con la mediana global (MCAR) y recalcular el monto	Alta	Misión 1 (resuelto)
Filas completamente duplicadas	Eliminar las filas repetidas	Alta	Semana 6
Precio unitario negativo	Detectar valores imposibles y tratarlos como atípicos: corregir o excluir	Alta	Semana 7

Problema	Estrategia propuesta	Prioridad	Semana de la Misión 2
Satisfacción: 15 variantes para 3 niveles	Normalizar a los tres niveles reales (Alto, Medio, Bajo)	Media	Semana 6
Correo con formato inválido	Validar el formato y marcar los que no sirven para enviar	Media	Semana 6
Satisfacción faltante (46.469)	Imputar la moda por canal de compra (MAR, concentrado en App)	Media	Misión 1 (resuelto)
Código postal no coincide con la ciudad (DIVIPOLA)	Comparar el departamento del código postal con la ciudad ya normalizada y corregir	Media	Semana 6
Peso imposible (más de 100 kg por producto)	Detectar por rango físico y tratar como atípico: corregir o marcar	Media	Semana 7
Fecha de pedido futura (imposible)	Marcar como inválidas y aplicar la regla de fecha máxima	Media	Semana 6
Código postal sin los 7 dígitos DIVIPOLA	Rellenar con el cero inicial a 7 dígitos y validar por departamento	Baja	Semana 6
Comentario faltante (texto libre opcional)	Valor constante "Sin comentario"	Baja	Misión 1 (resuelto)
Ciudad de tienda faltante (29.928)	Solo columna indicadora; no se imputa una ciudad falsa (MCAR, dato geográfico)	Baja	Misión 1 (resuelto)
Edad fuera de rango (negativa o mayor a 100)	Detectar por rango físico y ajustar o marcar como nulo	Baja	Semana 7
Fecha de stock futura (imposible)	Marcar como error de captura y corregir la fecha	Baja	Semana 6

3. Cierre

Al aplicar este plan durante la Misión 2, el dataset quedará sin pedidos duplicados, con las cinco columnas de texto (categoría, ciudad, canal, método de pago y satisfacción) unificadas, con las fechas en un solo formato y sin fechas futuras, con el código postal reconstruido a 7 dígitos y con los valores imposibles de precio, unidades, edad y peso corregidos o marcados.

En concreto, el dataset de ventas tendrá menos del 1 % de valores imposibles sin tratar, un formato único para las 12 ciudades donde opera NovaMarket y el inventario con una variable de antigüedad clara. Con eso, su confiabilidad pasa de media a alta y queda listo para reportar al comité.