

Informe de Calidad de Datos

Dataset de ventas NovaMarket

Cierre de la Misión 1

Autores (equipo): Sudo Sancocho (Analistas de Datos Juniors).

Dataset auditado: NovaMarket datos crudos (620 registros y 14 columnas).

Fecha de referencia: 4 de agosto de 2026.

1. Resumen ejecutivo

El dataset de ventas de NovaMarket tiene una confiabilidad media. Hoy sirve para explorar los datos de forma interna, pero todavía no está listo para reportar resultados al comité ni para alimentar modelos de decisión, porque arrastra varios errores importantes.

Los problemas más graves son la falta de consistencia en el texto (ciudad, categoría de producto y nivel de satisfacción, que afectan a más de la mitad de los registros), las fechas de compra imposibles (un 21,13 % con fecha futura), los pedidos duplicados y algunos valores imposibles en precio, unidades y código postal.

En conclusión, el dataset es confiable para diagnóstico, pero aún no para tomar decisiones. El Plan de Saneamiento explica cómo se va a corregir cada problema.

2. Alcance y metodología

Se auditó el archivo de ventas de NovaMarket, con 620 filas y 14 columnas, que cubre compras entre enero de 2025 y agosto de 2026, tomando como fecha de referencia el 4 de agosto de 2026. La revisión se hizo sobre las seis dimensiones de calidad de datos:

- **Completitud:** cuántos valores están presentes y cuántos faltan.
- **Exactitud:** si los valores son posibles (sin negativos, dentro de rango, sin fechas futuras).
- **Consistencia:** si un mismo dato se escribe siempre de la misma forma.
- **Validez:** si los valores cumplen el formato esperado (correo, fecha, código postal).
- **Unicidad:** si cada pedido aparece una sola vez.
- **Oportunidad:** si los datos siguen estando actualizados.

3. Hallazgos por dimensión

Todos los porcentajes se calculan sobre los 620 registros.

Completitud

Cuatro columnas tienen datos faltantes. El correo es la más afectada, con 104 vacíos (16,77 %); se concentran en las compras por la web, donde muchos clientes compran como invitados sin registrar su correo, y eso deja a esas personas fuera de las campañas por correo. Le siguen el

nivel de satisfacción con 46 (7,42 %), la ciudad con 31 (5,00 %) y el precio con 21 (3,39 %). En la Semana 4 se revisó por qué faltan: el correo y el precio dependen de otras columnas (canal y categoría), mientras que la ciudad quedó como un caso por confirmar con el área responsable. Las otras diez columnas están completas.

Exactitud

El error más grande son las fechas de compra en el futuro: 131 registros (21,13 %), que dañan cualquier reporte de ventas por fechas. También hay 32 edades fuera de rango (5,16 %), 29 registros con unidades negativas o con valores raros como 9999 y 5000 (4,68 %), y 19 precios negativos (3,06 %). Estos valores imposibles inflan o falsean directamente el cálculo de ingresos y de unidades vendidas.

Consistencia

Tres columnas de texto mezclan formas distintas de escribir lo mismo. La ciudad tiene 19 variantes que en realidad son 6 ciudades: 388 registros (62,58 %). La categoría de producto pasa de 17 a 6 valores reales: 362 registros (58,39 %). El nivel de satisfacción, de 8 a 3: 347 registros (55,97 %). Además, 41 registros (6,61 %) tienen un código postal que no coincide con su ciudad. Mientras el texto no se unifique, no se pueden agrupar bien las ventas por ciudad ni por categoría, y cualquier informe para Marketing o Logística sale distorsionado.

Validez

El código postal es el caso más llamativo: los 620 registros (100 %) quedaron con 4 o 5 dígitos en lugar de los 6 del formato colombiano, porque se perdieron los ceros a la izquierda. También hay 51 correos con formato inválido (8,23 %) y 22 fechas de compra con formato incorrecto o inexistente, como un 30 de febrero (3,55 %). Con el código postal así no se puede geolocalizar a los clientes ni calcular envíos, y los correos mal escritos rebotan al lanzar campañas.

Unicidad

Hay 20 filas totalmente repetidas (3,23 %) y, en total, 40 registros (6,45 %) comparten un id de pedido que debería ser único. Por eso ese identificador todavía no sirve como llave para contar pedidos, y los duplicados inflan los totales de ventas, unidades e ingresos.

Oportunidad

Con un límite de 90 días, 67 registros (10,81 %) tienen el inventario desactualizado, algunos de hace más de dos años. Otros 21 (3,39 %) tienen una fecha de stock en el futuro, lo que apunta a un error al capturar el dato. Como estas categorías rotan rápido, mostrar un stock viejo lleva a decisiones equivocadas de reposición y a posibles quiebres de inventario.

4. Catálogo de problemas priorizado

La tabla reúne los 19 problemas encontrados, de mayor a menor severidad. La severidad depende del porcentaje de registros afectados y de qué tan importante es la columna para el negocio.

Dimensión	Problema	Cant.	%	Severidad	Impacto en el negocio
Consistencia	Ciudad con 19 variantes de escritura para 6 ciudades reales	388	62,58	Alta	No se puede segmentar ni planear logística por ciudad.
Consistencia	Categoría de producto con 17 valores para 6 categorías reales	362	58,39	Alta	Distorsiona el análisis de ventas por categoría.
Consistencia	Nivel de satisfacción con 8 valores para 3 niveles reales	347	55,97	Alta	Impide medir bien la satisfacción del cliente.
Exactitud	Fecha de compra con fecha futura (imposible)	131	21,13	Alta	Daña cualquier reporte de ventas por fechas.
Compleitud	Correo faltante	104	16,77	Alta	Esos clientes no reciben campañas por correo.
Unicidad	Id de pedido repetido (20 pedidos duplicados)	40	6,45	Alta	No sirve como llave para contar pedidos.
Exactitud	Unidades negativas o con valores raros (9999 y 5000)	29	4,68	Alta	Corrompe el total de unidades vendidas.
Validez	Fecha de compra con formato inválido o inexistente	22	3,55	Alta	No se pueden ordenar esas ventas por tiempo.
Compleitud	Precio faltante	21	3,39	Alta	Bloquea el cálculo de ingresos de esos pedidos.
Unicidad	Filas completamente duplicadas	20	3,23	Alta	Infla pedidos, unidades e ingresos.
Exactitud	Precio negativo	19	3,06	Alta	Falsea la facturación real.
Validez	Código postal sin los 6 dígitos del formato colombiano	620	100,00	Media	No sirve para envíos ni geolocalización.
Oportunidad	Inventario desactualizado (más de 90 días)	67	10,81	Media	El stock mostrado no es el real: riesgo de quiebres.
Validez	Correo con formato inválido	51	8,23	Media	Esos correos rebotan al enviar campañas.
Compleitud	Nivel de satisfacción faltante	46	7,42	Media	Reduce la muestra de satisfacción.
Consistencia	Código postal que no coincide con la ciudad	41	6,61	Media	Genera errores de ruteo y geografía.
Exactitud	Edad fuera de rango (negativa o mayor a 100)	32	5,16	Media	Sesga la segmentación por edad.
Compleitud	Ciudad faltante	31	5,00	Media	No se ubica el pedido para logística.
Oportunidad	Fecha de stock en el futuro (imposible)	21	3,39	Baja	Indica un error al capturar la fecha.

5. Conclusión de confiabilidad

El dataset de NovaMarket tiene una confiabilidad media. Hoy sirve para explorar los datos y priorizar la limpieza, pero no para reportar ventas, medir satisfacción ni segmentar clientes con seguridad. Aplicando el Plan de Saneamiento durante la Misión 2, el dataset puede llegar a una confiabilidad alta y quedar listo para las decisiones del comité.