

Plan de Saneamiento

Dataset de ventas NovaMarket

Hoja de ruta de limpieza para la Misión 2

Autores (equipo): Sudo Sancocho (Analistas de Datos Juniors).

Documento asociado: Informe de Calidad de Datos de NovaMarket.

1. Propósito

El Informe de Calidad de Datos muestra qué tan mal están los datos. Este plan responde qué se va a hacer con cada problema y cuándo. La tabla ordena los 19 problemas del catálogo por prioridad, y a cada uno le asigna una estrategia y la semana de la Misión 2 en que se resuelve.

La prioridad combina dos cosas: el porcentaje de registros afectados y el impacto en el negocio. Cada problema del catálogo tiene su fila, así que ninguno queda sin plan.

Los cuatro problemas de datos faltantes ya se trataron en la Misión 1 (Semana 4). Aparecen al final de la tabla marcados como resueltos, para no perder el rastro de ninguno.

2. Tabla de saneamiento

Problema	Estrategia propuesta	Prioridad	Semana de la Misión 2
Ciudad con muchas variantes de escritura (19 formas para 6 ciudades)	Estandarizar el texto y mapear a un catálogo único de 6 ciudades	Alta	Semana 6
Categoría de producto con 17 valores para 6 categorías	Normalizar el texto y unir sinónimos en 6 categorías	Alta	Semana 6
Nivel de satisfacción con 8 valores para 3 niveles	Normalizar a los tres valores reales (Alto, Medio, Bajo)	Alta	Semana 6
Fecha de compra con fecha futura	Marcar como inválidas y aplicar la regla de fecha máxima	Alta	Semana 6
Id de pedido repetido (20 pedidos duplicados)	Deduplicar por id de pedido y dejar un solo registro por pedido	Alta	Semana 6
Filas completamente duplicadas	Eliminar las filas repetidas	Alta	Semana 6
Precio negativo	Marcar como inválido y corregir o excluir según la regla	Alta	Semana 6
Fecha de compra con formato inválido o inexistente	Pasar todo a un solo formato y marcar las fechas imposibles	Alta	Semana 6
Unidades negativas o con valores raros (9999 y 5000)	Tratar como valores atípicos y corregir o marcar	Alta	Semana 7
Edad fuera de rango (negativa o mayor a 100)	Detectar por rango válido y ajustar o marcar como nulo	Media	Semana 7
Código postal sin los 6 dígitos del formato colombiano	Rellenar con ceros a la izquierda y validar por ciudad	Media	Semana 6
Código postal que no coincide con la ciudad	Comparar con el más común de cada ciudad y corregir	Media	Semana 6
Correo con formato inválido	Validar el formato y marcar los que no sirven para enviar	Media	Semana 6

Problema	Estrategia propuesta	Prioridad	Semana de la Misión 2
Inventario desactualizado (más de 90 días)	Crear una variable de antigüedad y avisar a Operaciones	Media	Semana 10
Fecha de stock en el futuro	Marcar como error de captura y corregir la fecha	Baja	Semana 6
Correo faltante (104 registros)	Marcar con una columna indicadora y un valor genérico; no se inventa el correo	Alta	Misión 1 (resuelto)
Precio faltante (21 registros)	Imputar con la mediana del precio por categoría	Alta	Misión 1 (resuelto)
Nivel de satisfacción faltante (46 registros)	Imputar con el valor más frecuente por canal	Media	Misión 1 (resuelto)
Ciudad faltante (31 registros)	Solo marcar con columna indicadora; confirmar la causa antes de rellenar	Media	Misión 1 (resuelto)

3. Cierre

Al aplicar este plan durante la Misión 2, el dataset quedará sin pedidos duplicados, con las tres columnas de texto (ciudad, categoría y satisfacción) unificadas, con las fechas en un solo formato y sin fechas futuras, y con el código postal reconstruido a 6 dígitos en todos los registros.

En concreto, el dataset de ventas tendrá menos del 1% de valores imposibles sin tratar y un formato único para las 6 ciudades donde opera NovaMarket. Con eso, su confiabilidad pasa de media a alta y queda listo para reportar al comité.